Structura tehnică a datelor dorite pentru analiza de risc de credit

Anexă pentru identificarea unui set de date real din România - modelare predictivă, fairness, explicabilitate, robustețe și monitorizare

Scop. Documentul descrie structura ideală a unui set de date care să permită construirea și evaluarea în Python a unui model de risc de credit / probabilitate de default. Lista reprezintă situația ideală; metodologia poate fi adaptată în funcție de datele disponibile în practică.

1. Variabile și câmpuri dorite

Prioritate	Categorie	Variabilă / câmp dorit	Exemplu	Utilitate în analiză
OBLIGATORIU	Outcome	Indicator default / non-default	0 = non-default; 1 = default	Variabila țintă pentru model.
OBLIGATORIU	Outcome	Definiția default-ului	ex. 90+ zile întârziere în 12 luni	Necesara pentru interpretarea corectă a rezultatului și comparabilitate.
OBLIGATORIU	Credit	Valoarea creditului	50.000 RON	Variabilă predictivă de bază și context al expunerii.
OBLIGATORIU	Timp	Data acordării creditului / origination date	2024-03	Permite separare temporală, validare și analiză de stabilitate în timp.
RECOMANDAT	Credit	Tip produs	nevoi personale / ipotecar / card	Permite segmentarea și analizarea diferențelor de risc între produse.
RECOMANDAT	Credit	Durata creditului	60 luni	Caracteristică relevantă pentru profilul de risc.
RECOMANDAT	Credit	Rata dobânzii	8,5%	Poate influența atât riscul, cât și capacitatea de plată.
RECOMANDAT	Credit	Rata lunară	1.200 RON	Ajută la evaluarea capacității de rambursare.
RECOMANDAT	Financiar	Venit lunar	7.000 RON	Variabilă importantă pentru evaluarea capacității de plată.
RECOMANDAT	Financiar	Grad de îndatorare	35%	Indicator direct al presiunii financiare și al capacității de rambursare.
RECOMANDAT	Financiar	Datorii / expunere existentă	25.000 RON	Oferă context asupra expunerii totale a clientului.
RECOMANDAT	Credit history	Întârzieri anterioare	număr întârzieri / zile întârziere	Poate fi unul dintre cei mai puternici predictori ai riscului.
RECOMANDAT	Credit history	Număr de credite active	3	Descrie expunerea și comportamentul financiar curent.
RECOMANDAT	Credit history	Istoric de plată	punctual / întârzieri / restanțe	Permite modelarea comportamentului de rambursare.
RECOMANDAT	Fairness	Vârstă	35 ani sau categorie de vârstă	Permite comparații între grupuri pentru analiza de fairness.
RECOMANDAT	Fairness	Sex	F / M / altă codificare disponibilă	Permite evaluarea diferențelor de performanță și rezultate între grupuri.
RECOMANDAT	Fairness	Zonă geografică	județ / regiune	Permite identificarea diferențelor regionale și a eventualelor efecte de proxy.
RECOMANDAT	Fairness	Statut profesional	angajat / PFA / pensionar etc.	Util pentru segmentare, predicție și analiza diferențelor între grupuri.
NICE TO HAVE	Decizie	Decizia istorică a instituției	aprobat / respins	Permite compararea modelului cu decizia istorică și studierea procesului de aprobare.
NICE TO HAVE	Decizie	Scor de risc existent	ex. 640	Poate servi drept benchmark față de sistemul actual.
NICE TO HAVE	Decizie	Clasă / rating de risc	A / B / C	Permite analiză comparativă și segmentare suplimentară.
NICE TO HAVE	Financiar	Tip venit	salariu / pensie / activitate independentă	Adaugă granularitate în evaluarea profilului financiar.
NICE TO HAVE	Timp	Data ultimei observații / actualizări	2025-12	Sprijină analiza temporală, drift-ul și monitorizarea.

Prioritate	Categorie	Variabilă / câmp dorit	Exemplu	Utilitate în analiză
NICE TO HAVE	Demografic	Educație / stare civilă	categorii	Poate fi utilă pentru fairness și explicabilitate, dacă poate fi furnizată legal.

2. Cerințe generale privind setul de date

- **Volum:** câteva mii de observații ar fi deja utile; ideal 10.000+ dacă este posibil. Un volum mai mare permite estimări mai stabile, inclusiv pe subgrupuri.
- **Distribuția targetului:** setul trebuie să conțină atât cazuri de default, cât și non-default. Dacă default-urile sunt extrem de rare, analiza de performanță și fairness devine mai dificilă.
- **Perioadă:** ideal, datele să acopere mai mulți ani sau cel puțin mai multe perioade distincte, astfel încât să putem evalua stabilitatea modelului în timp.
- **Documentație:** ar fi foarte utilă o scurtă descriere a fiecărei variabile, a unităților de măsură și a codificărilor folosite.
- **Anonimizare:** nu sunt necesare nume, CNP, adresă exactă, telefon, e-mail, IBAN sau alte date care permit identificarea directă a persoanei. Datele pot fi anonimizate sau pseudonimizate.

3. Minimum necesar pentru proiect

Pentru modelarea de risc: o variabilă target clară (default / non-default), suficiente caracteristici financiare și/sau de credit și o componentă temporală (de exemplu data acordării creditului).

Pentru analiza de fairness: este necesară cel puțin una sau, ideal, mai multe variabile care permit definirea unor grupuri relevante. În lipsa acestora putem realiza modelarea de risc, însă componenta de fairness ar fi foarte limitată.

Notă importantă: nu este necesar ca setul de date să conțină toate câmpurile din tabel. Prioritățile indică ce este esențial și ce ar îmbunătăți analiza. Metodologia va fi adaptată la structura efectivă a datelor care pot fi furnizate legal și practic.